ЛАБОРАТОРНА РОБОТА №2
PYTHON-РЕАЛІЗАЦІЯ ПОПЕРЕДНЬОЇ ОБРОБКИ ДАТАСЕТІВ ДЛЯ ЗАДАЧ МАШИННОГО НАВЧАННЯ

Мета роботи

Метою лабораторної роботи є набуття практичних навичок попередньої обробки даних для задач машинного навчання, зокрема ознайомлення з процесами розділення набору даних на навчальну та тестову вибірки, кодування категоріальних ознак, масштабування числових змінних та формування фінального датасету, придатного для побудови моделей машинного навчання.

Теоретичні відомості

Попередня обробка даних є одним із ключових етапів у процесі побудови моделей машинного навчання, оскільки якість вхідних даних безпосередньо впливає на точність та стабільність моделі. Реальні набори даних часто містять пропущені значення, категоріальні змінні, різні шкали вимірювання ознак, а також неузгоджену структуру, що потребує приведення до єдиного формату.

Першим етапом у побудові моделі є розділення початкового набору даних на навчальну та тестову вибірки. Навчальна вибірка використовується для побудови та налаштування моделі, тоді як тестова вибірка застосовується для незалежної перевірки її якості. Такий підхід дозволяє оцінити здатність моделі узагальнювати нові дані. Важливо, що розділення виконується до етапу навчання будь-яких трансформацій, оскільки використання інформації з тестової вибірки на етапі навчання може призвести до витоку даних та завищення якості моделі.

Після розділення даних виконується обробка ознак. Категоріальні змінні не можуть бути безпосередньо використані в більшості алгоритмів машинного навчання, тому вони потребують перетворення у числовий формат. Найпоширенішим методом є one-hot encoding, який створює окрему бінарну змінну для кожної категорії ознаки. Це дозволяє уникнути штучного порядку між категоріями та забезпечує коректну інтерпретацію даних моделлю. У сучасних реалізаціях використовується клас OneHotEncoder, який навчається лише на навчальній вибірці та застосовується до тестової.

Числові ознаки часто мають різні масштаби значень, що може негативно впливати на роботу алгоритмів, чутливих до масштабу, таких як методи градієнтного спуску або алгоритми, що використовують відстані. Для вирішення цієї проблеми застосовується стандартизація, яка приводить дані до розподілу з нульовим середнім значенням і одиничною дисперсією. Для цього використовується StandardScaler, який також навчається тільки на навчальній вибірці.

Окремо виконується кодування цільової змінної, якщо вона є категоріальною. Для цього застосовується LabelEncoder, який перетворює класи у числові значення. Як і у випадку з іншими трансформаціями, навчання відбувається тільки на навчальній вибірці.

Фінальним етапом є об’єднання оброблених числових та закодованих категоріальних ознак у єдиний набір даних, який використовується для навчання та тестування моделі. Після цього дані можуть бути збережені у форматі CSV для подальшого використання.

Опис програмної реалізації у Python

Описаний процес реалізації у Python базується на бібліотеці **pandas** для роботи з даними та бібліотеці **scikit-learn** для виконання трансформацій. Загальна логіка алгоритму може бути представлена наступним чином.

Спочатку виконується завантаження набору даних, після чого відбувається розділення на ознаки та цільову змінну. Далі виконується поділ на навчальну та тестову вибірки. Після цього на навчальній вибірці навчаються перетворювачі даних, такі як кодувальник категоріальних ознак та стандартизатор числових значень. Отримані параметри застосовуються до тестової вибірки. Після цього оброблені ознаки об'єднуються у фінальні набори даних для навчання та тестування моделі. Таким чином, алгоритм реалізації такий:

1. Завантаження бібліотек для роботи з даними та машинним навчанням.
2. Завантаження датасету з файлу та визначення цільової змінної.
3. Розділення даних на *X* (ознаки) та *Y* (ціль).
4. Розділення на навчальну та тестову вибірки.
5. Визначення списку числових та категоріальних ознак.
6. Кодування навчальних категоріальних даних та перетворення обох вибірок.
7. Кодування навчальній цільової змінної та перетворення тестової вибірки.
8. Масштабування числових даних навчальної вибірки та трансформація тестової вибірки.
9. Об'єднання числових та категоріальних ознак у фінальні набори оброблених даних.
10. Збереження результатів у оброблені CSV-файли.

Хід роботи

Виконання лабораторної роботи №2 передбачає володіння деякими навичками засвоєними у лабораторній роботі №1, а саме основам використання GitHub та Google Colab. Відповідно, детально розписуватися вони не будуть. Етапи виконання лабораторної роботи №2 наступні:

1. Перейти на **GitHub**-репозиторій за посиланням: **github.com**
2. Завантажити файл *Lab2 - Google Colab.ipynb* та підготувати завантажений у лабораторній роботі №1 датасет у форматі *.csv* із назвою *synthetic_nls_kdd_X.csv*, де *X* — номер варіанту відповідно до вашого номеру у списку групи.
3. Перейти на платформу **Google Colab**: посилання.
4. На сторінці, що відкрилася, вибрати пункт «Завантажити» і або знайти файл *Lab2 - Google Colab.ipynb* на вашому ПК, або перетягнути його у саме вікно.
5. У реалізації Python, що відкрилася, у пункті «1. Введіть своє прізвище та ім'я, а також номер варіанту» ввести необхідні дані, наприклад:

```
student_name = "Костенко Уляна"
variant_number = 21
```

6. Вище знайти кнопку «Виконати всі», почекати деякий час, доки внизу блоку «2. Запустіть код, натисніть кнопку "Вибрати файли" та виберіть датасет, що відповідає номеру вашого варіанта» з'явиться кнопка «Вибрати файли», натиснути її та вибрати завантажений раніше файл *synthetic_nls_kdd_X.csv*.
7. Дочекатися, поки датасет завантажиться.
8. Дочекатися, доки код реалізації буде виконано та внизу блоку «3. Поділ на тренувальний і тестовий датасет, обробка даних, графічна візуалізація результатів обробки та генерація .png-файлу» з'явиться графічна візуалізація аналізу результатів обробки датасету.
9. Зліва натиснути на іконку «Файли», у новому вікні знайти та завантажити на свій ПК наступні файли:
   9.1. формату *ЛР2 — Прізвище Ім'я — Варіант X.png*.

9.2. Тренувальний датасет *train_processed.csv*.
9.3. Тестовий датасет *test_processed.csv*.

10. Завантажити у завдання лабораторної роботи №2 у Google Classroom наступні документи:

10.1. Графічний файл *ЛР2 — Прізвище Ім'я — Варіант X.png*, отриманий в результаті виконання вищеописаних кроків.
10.2. Тренувальний датасет *train_processed.csv*.
10.3. Тестовий датасет *test_processed.csv*.
10.4. Звіт з лабораторної роботи у форматі *.docx*, що включатиме детальний опис проведеної роботи та етапів її виконання, а також отриманих результатів. Проаналізувати відповідно до отриманої візуалізації результати обробки даних та зробити наступні висновки:

10.4.1. Які недоліки датасету мала виправити обробка даних перед навчанням нейронної мережі?
10.4.2. Чи були ці недоліки усунені внаслідок попередньої обробки?
10.4.3. Проаналізуйте графічну візуалізацію обробки датасету. Що було зроблено і які результати обробки?
10.4.4. Проаналізуйте тренувальний датасет *train_processed.csv* і порівняйте його із початковим датасетом *synthetic_nls_kdd_X.csv*. Чи очевидні зміни в результаті попередньої обробки?
10.4.5. На вашу думку, чи придатний в такому вигляді датасет *train_processed.csv* для тренування нейромережі?

10.5. Звіт закінчити відповідями на зазначені нижче питання для самоконтролю.

Висновки

У ході виконання лабораторної роботи було розглянуто та реалізовано основні етапи попередньої обробки даних для задач машинного навчання. Було встановлено, що коректний поділ даних на навчальну та тестову вибірки є критично важливим для запобігання витоку інформації та отримання об'єктивної оцінки моделі.

Також було доведено необхідність кодування категоріальних ознак, оскільки більшість алгоритмів машинного навчання працює лише з числовими даними. Використання one-hot кодування дозволяє уникнути неправильного впорядкування категорій та забезпечує коректну інтерпретацію ознак.

Окремо було розглянуто процес масштабування числових змінних, який забезпечує приведення ознак до єдиного масштабу та покращує стабільність навчання моделей.

У результаті роботи сформовано повний процес підготовки даних, який включає розділення датасету, кодування ознак, масштабування та формування фінальних навчальних і тестових наборів.

Питання для самоконтролю

1. Яке призначення розділення датасету на навчальну та тестову вибірки.
2. Чому важливо виконувати розділення даних до етапу попередньої обробки.
3. У чому полягає метод one-hot кодування та для чого він використовується.

4. Чому категоріальні ознаки не можуть бути використані безпосередньо у більшості алгоритмів машинного навчання.
5. Що таке масштабування ознак і чому воно є необхідним.
6. Який принцип масштабування числових ознак?
7. Чому параметри перетворень обчислюються тільки на навчальній вибірці?