ЛЕКЦІЯ 2
ТЕОРЕТИЧНІ АСПЕКТИ ПОПЕРЕДНЬОЇ ОБРОБКИ ДАТАСЕТІВ

Мета: дослідити структури датасетів у кібербезпеці, ознак та класів атак, сучасних загроз, а також вивчити теоретичні основи попередньої обробки даних у датасетах для подальшого використання у машинному навчанні.

ЗМІСТ

1. Вступ
2. Теоретичні аспекти попередньої обробки даних
3. Основні види попередньої обробки даних
4. Висновки
5. Питання для самоконтролю

1. ВСТУП

У попередній лекції були досліджені основні поняття і структура датасетів для навчання нейронних мереж у сфері кібербезпеки. Датасет (dataset) — це структурована таблиця даних, де рядки (samples) відповідають окремим подіям мережевого трафіку або активності користувача, а колонки (features, ознаки) описують характеристики цих подій, наприклад, кількість переданих байтів, тривалість сесії, протокол, порт, статус пакету. Окремою колонкою є мітка (Label), що визначає клас події. У датасеті NLS-KDD такими є normal (легітимна активність) або тип атаки (DoS, Probe, R2L, U2R).

Навчання нейронних мереж на основі датасетів мережевих подій може бути використано для протоколюванням цих подій та створення систем виявлення або попередження загроз (IDS/IPS, Intrusion Detection/Prevention System).

У сучасній кібербезпеці всі атаки класифікуються за **категоріями**, щоб спростити аналіз і виявлення загроз. Класи визначають, як саме атака впливає на систему і які механізми використання ресурсів або вразливостей вона застосовує. Основними категоріями атак у датасеті NLS-KDD є DoS, Probe, R2L та U2R.

Датасет NLS-KDD є історичним набором даних, актуальних для 1999 року. Сучасні види мережевих атак, не представлені у NLS-KDD, подані у таблиці 1.

Вид атаки	Опис	Потенційний базовий клас у NLS-KDD
Ransomware	Зловмисне шифрування файлів жертви з вимогою викупу.	U2R / DoS (може локально блокувати доступ до ресурсів).
Phishing	Перехоплення даних користувача через підроблені сайти чи листи.	R2L (віддалене отримання даних)
IoT Botnet attack	Використання мережі заражених пристроїв для DoS або спаму.	DoS / Probe
SQL Injection	Використання вразливостей у базі даних через веб-запити.	R2L / U2R (залежно від мети).
XSS (Cross-Site Scripting)	Виконання скриптів у браузері жертви.	R2L (віддалене порушення цілісності даних).

Таблиця 1. Сучасні види мережевих атак

Таким чином, навіть сучасні атаки можна частково віднести до класичних категорій: DoS, Probe, R2L, U2R.

2. ОБҐРУНТУВАННЯ НЕОБХІДНОСТІ ПОПЕРЕДНЬОЇ ОБРОБКИ ДАНИХ

Необроблений мережевий трафік — це набір даних, що не підходить для навчання нейронних мереж. Нейронні мережі очікують на вході стандартизовані числові вектори, водночас необроблені датасети містять дані, для яких характерні наступні проблеми:

1. Нерівномірність — різні ознаки мають різні формати, як числові так і текстові.
2. Різниця масштабів значень — тривалості з'єднання можуть бути в мілісекундах, а обсяг переданих байтів — у гігабайтах.
3. Незбалансованість — у реальному житті нормальний трафік складає 99%, а атаки — лише 1%, що створює проблему незбалансованості класів.

Окрім того, дані у необробленому вигляді часто містять пропущені значення (NaN)**,** некоректні або аномальні записи або ж текстові ознаки, які модель не може обробити без кодування.

Оскільки моделі машинного навчання працюють краще на нормалізованих даних, то без попередньої обробки даних модель може навчитися некоректно і бути упередженою, видавати помилки через некоректні значення чи бути чутливою до масштабу ознак.

3. ОСНОВНІ ВИДИ ПОПЕРЕДНЬОЇ ОБРОБКИ ДАНИХ

Основні види попередньої обробки даних наступні: очищення даних, кодування текстових ознак, нормалізація / стандартизація числових ознак, розділення на тренувальну і тестувальну частини, аналіз розподілу і балансування класів, проєктування ознак та зменшення розмірності.

3.1. Очищення даних (Data Cleaning)

При цьому виді обробки відбувається очищення непотрібних, повторюваних чи пропущених значень. Основні процеси наступні:

- видалення дублікатів — мережеві сканери часто генерують повторювані пакети;
- обробка пропущених значень — у випадку відсутності значення, необхідно або видалити весь рядок, або заповнити його (наприклад, нулем або середнім значенням по колонці).

3.2. Кодування текстових ознак (Encoding)

Оскільки нейронна мережа є математичною моделлю, то для її навчання текстові значення непридатні. Відповідно, їх необхідно кодувати у числові значення. Основні методи кодування наступні:

- Label Encoding (LE) — присвоєння кожному текстовому значенню числа (TCP=1, UDP=2), що може мати потенційний недолік у створенні упередженості нейронної мережі через різницю значень;
- One-Hot Encoding (OHE) — створення окремих колонок для кожного типу текстових значень, в яких 1 (одиниця) стоятиме лише в потрібній колонці.

3.3. Нормалізація / стандартизація числових ознак

Для запобігання упередженості щодо важливості різних колонок при навчанні нейронної мережі їй на вході необхідно отримати числові значення, приведені до одного масштабу. Основні типи обробки наступні:

- нормалізація — приведення всіх значень до діапазону [0, 1] за формулою:

$x_{\text{нове}} = \frac{x - x_{\text{мін}}}{x_{\text{макс}} - x_{\text{мін}}}$, де $x_{\text{нове}}$ — нормалізоване значення, $x_{\text{мін}}$ — мінімальне значення в колонці, $x_{\text{макс}}$ — максимальне значення в колонці.

• стандартизація — центрування даних навколо нуля з одиничним відхиленням.

3.4. Розділення датасету на тренувальну та тестувальну частину

При цьому виді обробки датасет розділяється на тренувальний та тестувальний варіанти. В подальшому тренувальний датасет використовується для навчання нейронної мережі, а тестувальний — для перевірки, як модель працює на нових, невідомих даних. При цьому важливо, щоб дані для тестування не потрапляли у тренувальні дані, щоб оцінка точності була реалістичною.

Водночас, оскільки датасет NSL-KDD поширюється в освітніх цілях, то він вже доступний у тренувальному та тестувальному варіантах. Відповідно, в його розділенні необхідності немає.

3.5. Аналіз розподілу і балансування класів (Class Distribution Analysis)

При цьому виді обробки відбувається перевірка, чи немає сильного переважання одного класу подій (наприклад, надто багато Normal). Якщо навчити мережу на датасеті, де 999 подій є нормальною активністю, а лише 1— атакою, то нейронна мережа просто навчиться завжди відповідати «Норма» і матиме точність 99.9%, але при цьому пропустить атаку. Методи балансування ознак наступні:

• Oversampling — штучне створення нових зловмисних подій за рахунок копіювання рідкісних атак або інтерполяції існуючих;

• Undersampling — видалення частини прикладів нормального трафіку.

3.6. Проєктування ознак (Feature Engineering)

Це процес створення нових ознак на основі наявних, наприклад, розділення однієї ознаки на декілька більш детальних у випадку логічної необхідності.

3.7. Зменшення розмірності (Dimensionality Reduction)

Сучасні датасети (наприклад, CIC-IDS2017 або UNSW-NB15) мають понад 80 ознак і багато з них корелюють між собою, що може перевантажити і ускладнити навчання нейронної мережі. Відповідно, може виникнути необхідність зменшення кількості ознак. Зокрема, для цього можна використати метод головних компонент (Principal Component Analysis, PCA) що дозволяє стиснути 80 ознак у 10 найважливіших без значної втрати інформації.

4. ВИСНОВКИ

1. Навчання нейронних мереж передбачає отримання на вході вектору очищених, нормалізованих, стандартизованих та збалансованих числових значень.
2. Необроблений мережевий трафік не підходить для навчання нейронних мереж через різницю масштабів значень, наявність непотрібних чи помилкових значень або текстових ознак.
3. Основними методами обробки даних у датасеті є наступні: очищення, кодування текстових ознак, нормалізація / стандартизація числових ознак, розділення на тренувальну і тестувальну частини, аналіз розподілу і балансування класів, проєктування ознак, зменшення розмірності.
4. Після проведення попередньої обробки даних датасет стає придатним для подальшого навчання нейронної мережі.

5. ПИТАННЯ ДЛЯ САМОКОНТРОЛЮ

1. Чому необроблений мережевий трафік не підходить для навчання нейронної мережі?
2. Які проблеми характерні для необробленого мережевого трафіку?
3. Перерахуйте основні методи попередньої обробки даних.
4. Які процеси відбуваються при очищенні даних у датасетах?
5. Чому необхідно кодувати текстові ознаки у датасетах?
6. Опишіть метод кодування текстових ознак Label Encoding.
7. Опишіть метод кодування текстових ознак One-Hot Encoding.
8. Чому необхідна нормалізація чи стандартизація числових ознак?
9. Опишіть процес нормалізації числових ознак.
10. Опишіть процес стандартизації числових ознак.
11. Чому необхідно розділити датасет на тренувальний та тестувальний?
12. Що відбувається при аналізі розподілу класів і в чому небезпека незбалансованості класів?
13. Опишіть метод балансування класів Oversampling.
14. Опишіть метод балансування класів Undersampling.
15. Опишіть процес проєктування ознак.
16. Опишіть процес зменшення розмірності датасетів.